SQL查询操作处理流程

SQL查询

这里看到书上讲述SQL的查询处理,在SQL中查询是通过select语句以及一些辅助的子句来实现需要的输出,这里使用的是mysql,首先,要理解物理表和虚拟表的区别,物理表就是存储在文件系统上的一个或者多个文件,按照相应的存储数据结构将每一行的数据存储,虚拟表是我们在物理表的基础上构建出来的,可能是全部的表结构,也可能是表中的部分字段或者部分行,甚至可能是表中某些字段经过某种运算之后的结果。但是SQL语言不像C/C++/JAVA这类语言一样,它们的主要区别在于SQL给你一个需求,不关心它是怎么实现的,真正的实现由数据库完成,当然不同的数据库可能会有差别很大的实现方式,而C/C++这类的语言,我们必须一步步的实现,完成指定的功能。所以SQL的内部实现过程我们不用关心,但是对于查询请求,它的执行过程和执行顺序对我们对结果的认识有很大的影响,但是真正的执行过程需要深入数据库内部才能明白使用哪些方式(例如索引)优化,所以这里我们重点看一下查询请求每个子句的执行顺序。

标准的SQL查询语句的结果如下所示:

```
(8) SELECT x, xx, xxx, xxxx \
(9)
      DISTINCT <x, xx,...> \
(1)
       FROM <table1, table2, table3,...> \
       <join_type>JOIN<join_table> \
(3)
(2)
        ON <join_condition> \
(4)
      WHERE <where condition> \
        GROUP BY <group_by_list> \
(5)
       WITH[CUBE | ROLLUP] \
(6)
(7)
       HAVING <having_condition> \
(10)
       ORDER BY <order_by_list> \
       LIMIT climit number> OFFSET <offset number> ;
(11)
```

每个子句执行的次序已经在前面进行了标记,在一一介绍这些子句之前,我们要先明白,执行这个命令的输入是这些表名、条件(ON、WHERE 和HAVING)以及一些字段名(SELECT,DISTINCT、ORDER BY、GROUP BY),其中表名标识的是物理存储的表,字段名是每一个表的字段的名称,条件是针对字段的或者该字段上执行的聚集函数的值得逻辑表达式。这些子句的每一步都是产生一个逻辑关系表。

执行流程

FROM操作

这一步的输入是多个表,在这一步是对多个关系表执行笛卡尔积操作,生成的结果是VT1,假设有3个表,t1、t2和t3,三个表分别有r1、r2、r3行,每个表有c1、c2、c3个字段,那么执行笛卡尔积得到的VT1则有r1r2r3行,有c1+c2+c3个字段。

ON子句

所以,我们可以把NULL视为未知状态,所以两个未知状态也不是相等的。但是在条件判断的时候,我们要分出TRUE或者FALSE,因为我们要根据这个结果判断是否淘汰这一行,在ON子句中,是将NULL视为FALSE的,所以如果某一行的该字段是NULL,那么它将会被淘汰。例如:

接着,我们看一下将这一个表执行完笛卡尔积之后再执行ON操作得到的结果:

可以看出,在执行笛卡尔积之后生成的VT1表应该含有9行,其中t2.b应该包含'hello'、'world和'NULL三种,这里只返回了'world',所以在判断 NULL!= 'hello'的时候虽然返回的是NULL,但是ON子句把它当做了FALSE。

所以在ON子句的操作之后,得到了表2,这里面只包含满足ON后面逻辑操作计算得到TRUE的行(淘汰计算结果为FALSE或者NULL的行)。

添加外部行

这一步执行的是添加外部行的操作,这里针对的是外部JOIN的,因为外部JOIN需要保证进行连接的左边的表或者右边的表中每一行都出现在VT2中,但是如果在ON操作的时候这一行被淘汰了呢?那么就进行补充添加,仅仅根据左连接或者右连接添加上左边或者右边表中缺失的行,然后其它的字段补充NULL就可以了,得到了VT3。

可以从上例中看到,在笛卡尔积计算之后,一共产生了9行,然后执行ON操作,只剩下了3行满足条件的,而条件是t2.b!='hello',这就导致了t2表中只剩下了b='hello'的那一行,如上上一个图所示,但是如果执行了右外连接的操作,那么需要添加t2表(因为t2是连接操作右边的那个表)中缺失的每一行(这里需要添加两行),对于这两行除了t2字段外的其他字段,都补充NULL就可以了。如果将上例中的t1和t2换一下,然后再讲right join换成 left join,可以得到类似的结果,只不过补充的NULL出现在是右边。

WHERE子句

这一步执行的是我们最熟悉的WHERE子句,这一步是在VT3的基础上执行条件过滤,同样,只保留条件计算得到TRUE的行,淘汰结果为FALSE和NULL的行。将返回的结果标记为VT4。

但是,在WHERE子句执行的时候需要注意一些问题:

- 由于WHERE是第四步执行的,而此时并没有执行GROUP BY子句,所以不能再WHERE子句中使用聚集函数运算之后的结果作为条件运算的输入,这将会导致执行出错。mysql> select * from T1 as t1 right join T1 as t2 on t2.b!= 'hello' where count(t1.b)!= 1; ERROR 1111 (HY000): Invalid use of group function
- 由于在执行WHERE的时候并没有执行到SELECT操作,所以在SELECT操作中出现的as别名将不能用在WHERE子句中。 mysql> select t1.a as A from T1 as t1 right join T1 as t2 on t2.b != 'hello' A != 10; ERROR 1064 (42000): You have an error in your SQL syntax; check the manual that corresponds to your MySQL server version for the right syntax to use near 'A != 10' at line 1
- 要明确WHERE是在添加缺失行之后执行的,而ON执行在添加缺失行之前,所以如果在ON和WHERE使用相同的逻辑计算,得到的结果可能不是相同的。

GROUP BY子句

这一步执行的是分组的操作,在VT4的基础上,根据GROUP BY确定的列进行分组,在GROUP BY子句中会认为所有的NULL都是相同的,而不是NULL!= NULL,将它们分在一组,例如:

WITH子句

with子句分为ROLLUP和CUBE两种,这两种我们基本上用不到,CUBE在mysql也不支持,ROLLUP只是在得到的结果添加额外的一行。

这里不探讨ROLLUP的作用了,假设它生成的结果为VT6

HAVING子句

执行HAVING子句,这个子句的作用也是将汇聚之后的每一组(在GROUP BY指定的列上相同的行为一组)进行判断,这是有区别与ON和WHERE 子句的,它们都是对于上一个操作结果中的每一行进行判断,而HAVING是对每一组。这里可以是对一个或者多个字段的判断,也可以是每一个组中执行汇聚函数的判断。生成的结果是VT7。 但是,在HAVING执行的时候需要注意,虽然在GROUP BY的时候将执行列为NULL的划分到同一组了,但是对于某一列为NULL的时候,执行这一列的count操作会被认为为0的,例如:

但是在计算count(*)的时候,某一行即使都是NULL,也会被算作一行的,例如:

这一点需要在具体的应用上特别注意,尤其是使用OUTER JOIN的时候会添加一些NULL,可能由于使用count(*)而不是count(字段名)导致不正确的计数。

SELECT子句

这一步执行的是SELECT操作,然后SELECT出现在查询语句的最前面,但是它是到了第八步才被执行,这一步是对VT7上的选择SELECT指定的列。生成VT8。另外,在SELECT中不能对前面字段的别名进行使用,也就是SELECT的别名只有在整个SELECT子句执行完之后才有效。

这一点需要在具体的应用上特别注意,尤其是使用OUTER JOIN的时候会添加一些NULL,可能由于使用count(*)而不是count(字段名)导致不正确的计数。

OFFSET...LIMIT子句

最后一步执行的是OFFSET ... LIMIT子句,这一步就是在上面生成的VT10表中,从指定的OFFSET开始选择指定的行数,OFFSET也可以省略,而写成LIMIT m, n.它的含义和LIMIT n OFFSET m是一样的。

总结

好了,一般的SQL查询语句都是按照这个顺序执行的,当然具体的逻辑查询和物理查询方案这里我们没有涉及,仅仅是介绍每一步的执行顺序和它的作用,当然其中还涉及一些mysql中的规则,以后使用SQL查询语句之前要首先理好这个顺序,然后再去考虑使用什么样的查询语句才能得到希望的结果。